



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Системы обработки информации и управления

ОТЧЕТ
ПО ЛАБОРАТОРНОЙ РАБОТЕ №2
ПО ДИСЦИПЛИНЕ
«МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ»
НА ТЕМУ:
Обработка признаков (часть 2).

Студент ИУ5И-22М
(Группа)

Ду Линьсянь
(Подпись, дата) (И.О.Фамилия)

Преподаватель

Ю.Е.Гапанюк
(Подпись, дата) (И.О.Фамилия)

2026 г.

ВВЕДЕНИЕ

Обработка признаков (Feature Engineering) в машинном обучении - это процесс создания, преобразования и выбора наиболее релевантных признаков (features) из исходных данных для улучшения производительности и точности моделей машинного обучения. Этот процесс включает в себя: очистку данных и удаление аномалий; выделение признаков для решения задачи; подготовку данных.

Цель лабораторной работы: изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей.

ЗАДАНИЕ

Для выбранного датасета на основе материалов лекций решить следующие задачи:

1. Масштабирование признаков (не менее чем тремя способами);
2. Обработку выбросов для числовых признаков (по одному способу для удаления выбросов и для замены выбросов);
3. Обработку по крайней мере одного нестандартного признака (который не является числовым или категориальным);
4. Отбор признаков:
 - один метод из группы методов фильтрации (filter methods);
 - один метод из группы методов обертывания (wrapper methods);
 - один метод из группы методов вложений (embedded methods).

ХОД ВЫПОЛНЕНИЯ РАБОТЫ

Часть 1. Текстовое описание набора данных

Для выполнения лабораторной работы был выбран набор данных Wine Quality (качество красного вина). Этот набор данных содержит информацию о различных химических характеристиках вина, влияющих на его качество.

Набор данных содержит следующие признаки:

- fixed acidity (фиксированная кислотность)
- volatile acidity (летучая кислотность)
- citric acid (лимонная кислота)
- residual sugar (остаточный сахар)
- chlorides (хлориды)
- free sulfur dioxide (свободный диоксид серы)
- total sulfur dioxide (общий диоксид серы)
- density (плотность)
- pH (кислотность)
- sulphates (сульфаты)
- alcohol (алкоголь)

Целевая переменная: quality (качество вина по шкале от 3 до 8)

Размер датасета: 1599 строк, 12 столбцов.

```

Статистика:
      fixed acidity  volatile acidity  citric acid  residual sugar \
count    1599.000000         1599.000000    1599.000000      1599.000000
mean      8.319637           0.527821      0.270976        2.538806
std       1.741096           0.179060      0.194801        1.409928
min       4.600000           0.120000      0.000000        0.900000
25%      7.100000           0.390000      0.090000        1.900000
50%      7.900000           0.520000      0.260000        2.200000
75%      9.200000           0.640000      0.420000        2.600000
max      15.900000          1.580000      1.000000       15.500000

      chlorides  free sulfur dioxide  total sulfur dioxide  density \
count    1599.000000         1599.000000      1599.000000    1599.000000
mean      0.087467          15.874922         46.467792      0.996747
std       0.047065          10.460157         32.895324      0.001887
min       0.012000           1.000000          6.000000      0.990070
25%      0.070000           7.000000         22.000000      0.995600
50%      0.079000          14.000000         38.000000      0.996750
75%      0.090000          21.000000         62.000000      0.997835
max       0.611000          72.000000        289.000000      1.003690

      pH  sulphates  alcohol  quality
count    1599.000000    1599.000000    1599.000000    1599.000000
mean      3.311113      0.658149     10.422983      5.636023
std       0.154386      0.169507      1.065668      0.807569
min       2.740000      0.330000      8.400000      3.000000
25%      3.210000      0.550000      9.500000      5.000000
50%      3.310000      0.620000     10.200000      6.000000
75%      3.400000      0.730000     11.100000      6.000000
max       4.010000      2.000000     14.900000      8.000000

```

Рисунок 1: Информация о наборе данных Wine Quality

```

Первые 5 строк:
      fixed acidity  volatile acidity  citric acid  residual sugar  chlorides \
0           7.4           0.70           0.00           1.9           0.076
1           7.8           0.88           0.00           2.6           0.098
2           7.8           0.76           0.04           2.3           0.092
3          11.2           0.28           0.56           1.9           0.075
4           7.4           0.70           0.00           1.9           0.076

      free sulfur dioxide  total sulfur dioxide  density  pH  sulphates \
0           11.0           34.0           0.9978  3.51           0.56
1           25.0           67.0           0.9968  3.20           0.68
2           15.0           54.0           0.9970  3.26           0.65
3           17.0           60.0           0.9980  3.16           0.58
4           11.0           34.0           0.9978  3.51           0.56

      alcohol  quality
0           9.4           5
1           9.8           5
2           9.8           5
3           9.8           6
4           9.4           5

```

Рисунок 2: Первые 5 строк набора данных Wine Quality

Часть 2. Масштабирование признаков

Масштабирование признаков - это изменение диапазона измерения признака с целью улучшения качества построения модели.

В данной работе были использованы четыре метода масштабирования признаков: Min-Max Scaling, Standard Scaling (Z-score), Robust Scaling и MaxAbs Scaling. В качестве тестового признака был выбран `alcohol` (содержание алкоголя).

Таблица 1 - Сравнение методов масштабирования (признак 'alcohol')

Метод	Min	Max	Mean	Std
Original	8.4000	14.9000	10.4230	1.0657
Min-Max	0.0000	1.0000	0.3112	0.1639
Standard	-1.8989	4.2025	0.0000	1.0003
Robust	-1.1250	2.9375	0.1394	0.6660
MaxAbs	0.5638	1.0000	0.6995	0.0715




Рисунок 3: Распределение признака alcohol после масштабирования

Вывод: Все методы сохраняют форму распределения, но изменяют масштаб данных. Min-Max сжимает данные в диапазон $[0,1]$; Standard Scaling центрирует данные относительно нуля ($\text{mean}=0$, $\text{std}=1$); Robust Scaling устойчив к выбросам; MaxAbs сохраняет знак исходных данных.

Часть 3. Обработка выбросов для числовых признаков

Выбросы - это элементы выборки, существенно отличающиеся от остальных элементов. Для признака `fixed acidity` был использован метод обнаружения выбросов на основе межквартильного размаха (IQR).

Результаты обработки выбросов:

- Q1 (25% квартиль): 7.10
- Q3 (75% квартиль): 9.20
- IQR: 2.10
- Нижняя граница: 3.95
- Верхняя граница: 12.35
- Количество выбросов: 49 (3.06% от всех данных)

1. Удаление выбросов: размер датасета уменьшился с 1599 до 1550 записей.

2. Замена выбросов: максимальное значение изменилось с 15.90 до 12.35.

Рисунок: Обработка выбросов признака fixed acidity




Рисунок 4: Обработка выбросов признака fixed acidity

Вывод: Оба метода эффективно устраняют влияние выбросов на распределение данных.

Часть 4. Обработка нестандартного признака (дата/время)

В качестве нестандартного признака был создан и обработан признак ``purchase_date`` (дата покупки).

Основные методы обработки дат:

1. Извлечение компонентов даты: год, месяц, день, день недели, квартал, день года.
2. Создание циклических признаков: $\sin/\cos$ преобразование для месяца и дня недели.
3. Признаки на основе разницы дат: выходной ли день, сезон года.

Результат: Из одного признака ``purchase_date`` было создано 13 новых числовых признаков.




Рисунок 5: Результаты обработки даты как нестандартного признака

Часть 5. Отбор признаков

5.1. Метод фильтрации (Filter Method) - SelectKBest + Mutual Information

Метод взаимной информации (Mutual Information) оценивает зависимость между признаком и целевой переменной.

Результаты Mutual Information:

Признак	MI Score
alcohol	0.184430
density	0.091542
sulphates	0.090910
volatile acidity	0.090465
citric acid	0.061084

Выбранные признаки (k=4): alcohol, density, sulphates, volatile acidity.

Рисунок: Метод фильтрации (Mutual Information)




Рисунок 6: Визуализация результатов метода фильтрации (Mutual Information)

5.2. Метод обертывания (Wrapper Method) - RFE

Метод рекурсивного исключения признаков (RFE) с линейной регрессией.

Выбранные признаки (k=4): volatile acidity, chlorides, density, sulphates.




Рисунок 7: Визуализация результатов метода обертывания (RFE)

5.3. Вложенные методы (Embedded Methods) - Lasso и Random Forest

Lasso (L1-регуляризация): выбрал 6 признаков с ненулевыми коэффициентами: volatile acidity, sulphates, alcohol, fixed acidity, free sulfur dioxide, total sulfur dioxide.

Random Forest: выбрал 3 признака с важностью выше среднего: alcohol, sulphates, volatile acidity.




Рисунок 8: Визуализация результатов вложенных методов (Lasso и Random Forest)

Часть 6. Сравнение методов отбора признаков

Таблица 2 - Сравнение методов отбора признаков

Метод	Выбранные признаки
Filter (Mutual Info)	alcohol, density, sulphates, volatile acidity
Wrapper (RFE)	volatile acidity, chlorides, density, sulphates
Embedded (Lasso)	volatile acidity, sulphates, alcohol, fixed acidity, free SO ₂ , total SO ₂
Embedded (Random Forest)	alcohol, sulphates, volatile acidity

Рейтинг важности признаков (по всем методам):

- 4/4 методов: volatile acidity, sulphates
- 3/4 методов: alcohol
- 2/4 методов: density
- 1/4 методов: fixed acidity, free sulfur dioxide, chlorides, total sulfur dioxide

Рисунок: Итоговые результаты отбора признаков




Рисунок 9: Сравнительная диаграмма методов отбора признаков

ЗАКЛЮЧЕНИЕ

В ходе выполнения данной лабораторной работы был проведен комплексный анализ обработки признаков на основе набора данных Wine Quality.

Были выполнены следующие задачи:

1. Масштабирование признаков: применены 4 метода (Min-Max, Standard, Robust, MaxAbs). Все методы сохранили форму распределения исходных данных.
2. Обработка выбросов: обнаружено 49 выбросов (3.06%) в признаке `fixed acidity`. Применены два подхода: удаление и замена граничными значениями.
3. Обработка нестандартного признака: создан и обработан признак "дата". Из одного признака создано 13 новых числовых признаков.
4. Отбор признаков: использованы Filter (Mutual Information), Wrapper (RFE) и Embedded (Lasso + Random Forest) методы.

Общий вывод: Наиболее важными признаками для предсказания качества вина являются volatile acidity (летучая кислотность), sulphates (сульфаты) и alcohol (содержание алкоголя), что соответствует реальным химическим закономерностям виноделия.