



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Системы обработки информации и управления

ОТЧЕТ

ПО ЛАБОРАТОРНОЙ РАБОТЕ №1

ПО ДИСЦИПЛИНЕ «МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ»

НА ТЕМУ: Создание "истории о данных"

Студент ИУ5И-22М
(Группа)

Ду Линьсянь
(Подпись, дата) (И.О.Фамилия)

Преподаватель

Ю.Е.Гапанюк
(Подпись, дата) (И.О.Фамилия)

ЗАДАНИЕ

Выбрать набор данных (датасет), содержащий категориальные и числовые признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.) Просьба не использовать датасет, на котором данная задача решалась в лекции.

Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:

1. устранение пропусков в данных;
2. кодирование категориальных признаков;
3. нормализация числовых признаков.

ХОД ВЫПОЛНЕНИЯ РАБОТЫ

1 Текстовое описание набора данных

Название набора данных: Titanic (данные о пассажирах «Титаника»)

Источник: Открытый набор данных Kaggle

Особенности: Содержит одновременно категориальные и числовые признаки, а также пропуски в данных – полностью соответствует требованиям задания

Описание признаков:

Признак	Тип	Описание	Пропуски
Age	Числовой	Возраст пассажира	Есть (177)
Fare	Числовой	Стоимость билета	Нет
SibSp	Числовой	Кол-во братьев/супругов	Нет
Parch	Числовой	Кол-во родителей/детей	Нет
Sex	Категориальный	Пол (male/female)	Нет
Embarked	Категориальный	Порт посадки (S/C/Q)	Есть (2)
Cabin	Категориальный	Номер каюты	Есть (687, не обрабатывается)

2 Загрузка и первичный анализ данных

Загружен набор данных Titanic, выведена информация о размере данных, первых 5 строках и статистике пропусков.

url =

<https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv>

```

df = pd.read_csv(url)
# Отображение основной информации о необработанных данных
print("="*50)
print("Информация об исходном наборе данных")
print("="*50)
print(f"Размер набора данных: {df.shape}")
print("\nПервые 5 строк данных:")
print(df.head())
print("\nСтатистика пропущенных значений:")
print(df.isnull().sum())

```

Набор данных содержит 891 строку и 15 столбцов.

```

... =====
Информация об исходном наборе данных
=====
Размер набора данных: (891, 12)

Первые 5 строк данных:
  PassengerId  Survived  Pclass  \
0             1         0       3
1             2         1       1
2             3         1       3
3             4         1       1
4             5         0       3

                                Name  Sex  Age  SibSp  \
0                        Braund, Mr. Owen Harris    male  22.0      1
1  Cumings, Mrs. John Bradley (Florence Briggs Th...  female  38.0      1
2                        Heikkinen, Miss. Laina    female  26.0      0
3  Futrelle, Mrs. Jacques Heath (Lily May Peel)    female  35.0      1
4      Allen, Mr. William Henry    male  35.0      0

   Parch  Ticket   Fare Cabin Embarked
0      0   A/5 21171   7.2500   NaN      S
1      0    PC 17599  71.2833   C85      C
2      0  STON/O2. 3101282   7.9250   NaN      S
3      0   113803   53.1000  C123      S
4      0   373450   8.0500   NaN      S

Статистика пропущенных значений:
PassengerId    0
Survived        0
Pclass          0
Name            0
Sex             0
Age            177
SibSp          0
Parch          0
Ticket         0
Fare           0
Cabin        687
Embarked        2
dtype: int64

```

Рисунок 1 – Информация об исходном наборе данных

3 Задача 1: Устранение пропусков

Пропуски в числовом признаке Age заполнены медианой (28.00), пропуски в категориальном признаке Embarked заполнены модой ('S').

```
df_missing = df.copy()
age_median = df_missing['Age'].median()
df_missing['Age'] = df_missing['Age'].fillna(age_median)
print(f'Age заполнены медианой: {age_median:.2f}')
embarked_mode = df_missing['Embarked'].mode()[0]
df_missing['Embarked'] = df_missing['Embarked'].fillna(embarked_mode)
print(f'Embarked заполнены модой: '{embarked_mode}''')
print("\nПропуски после обработки:")
print(df_missing[['Age', 'Embarked']].isnull().sum())
```

После обработки пропуски в Age и Embarked полностью устранены. Cabin не обрабатывался из-за высокой доли пропусков (77%).

```
...
=====
Задание 1: Обработка пропущенных значений
=====
Пропуски в Age заполнены медианой 28.00
Пропуски в Embarked заполнены модой 'S'
Доля пропусков в Cabin: 77.10% (в этом эксперименте не обрабатываем)

Статистика пропусков после обработки:
Age      0
Embarked 0
dtype: int64
```

Рисунок 2 – Результат обработки пропусков

4 Задача 2: Кодирование категориальных признаков

Для признака Sex применено Label Encoding (female→0, male→1). Для признака Embarked применено One-Hot Encoding с созданием двух фиктивных переменных: Embarked_Q и Embarked_S.

```

df_encoded = df_missing.copy()
# Label Encoding для Sex
le = LabelEncoder()
df_encoded['Sex_LabelEncoded'] = le.fit_transform(df_encoded['Sex'])
print(f"Label Encoding Sex: {dict(zip(le.classes_, le.transform(le.classes_)))}")
# One-Hot Encoding для Embarked
ohe = OneHotEncoder(sparse_output=False, drop='first')
embarked_encoded = ohe.fit_transform(df_encoded[['Embarked']])
embarked_columns = [f"Embarked_{cat}" for cat in ohe.categories_[0][1:]]
embarked_df = pd.DataFrame(embarked_encoded, columns=embarked_columns,
index=df_encoded.index)
df_encoded = pd.concat([df_encoded, embarked_df], axis=1)
print("\nРезультат кодирования (первые 5 строк):")
print(df_encoded[['Sex', 'Sex_LabelEncoded', 'Embarked'] +
embarked_columns].head())

```

Label Encoding преобразовал бинарный признак Sex в 0/1. One-Hot Encoding для Embarked создал 2 столбца, избежав мультиколлинеарности (drop='first')

```

=====
Задание 2: Кодирование категориальных признаков
=====
Сопоставление меток для Sex: {'female': np.int64(0), 'male': np.int64(1)}
Новые столбцы после One-Hot кодирования Embarked: ['Embarked_Q', 'Embarked_S']

Часть данных после кодирования (первые 5 строк, только столбцы, связанные с кодированием):

```

	Sex	Sex_LabelEncoded	Embarked	Embarked_Q	Embarked_S
0	male	1	S	0.0	1.0
1	female	0	C	0.0	0.0
2	female	0	S	0.0	1.0
3	female	0	S	0.0	1.0
4	male	1	S	0.0	1.0

Рисунок 3 – Результат кодирования категориальных признаков

5 Задача 3: Нормализация числовых признаков

Для числовых признаков (Age, Fare, SibSp, Parch) выполнены два типа нормализации: стандартизация (Z-score) и Min-Max нормализация.

```
df_normalized = df_encoded.copy()
numeric_features = ['Age', 'Fare', 'SibSp', 'Parch']

# Стандартизация
scaler_std = StandardScaler()
std_values = scaler_std.fit_transform(df_normalized[numeric_features])
df_normalized['Age_std'] = std_values[:, 0]
df_normalized['Fare_std'] = std_values[:, 1]
df_normalized['SibSp_std'] = std_values[:, 2]
df_normalized['Parch_std'] = std_values[:, 3]

# Min-Max нормализация
scaler_minmax = MinMaxScaler()
minmax_values = scaler_minmax.fit_transform(df_normalized[numeric_features])
df_normalized['Age_minmax'] = minmax_values[:, 0]
df_normalized['Fare_minmax'] = minmax_values[:, 1]
df_normalized['SibSp_minmax'] = minmax_values[:, 2]
df_normalized['Parch_minmax'] = minmax_values[:, 3]
print("Статистика после стандартизации:")
print(df_normalized[['Age_std', 'Fare_std', 'SibSp_std', 'Parch_std']].describe().round(4))
print("\nСтатистика после Min-Max нормализации:")
print(df_normalized[['Age_minmax', 'Fare_minmax', 'SibSp_minmax',
'Parch_minmax']].describe().round(4))
```

После стандартизации среднее каждого признака ≈ 0 , стандартное отклонение = 1. После Min-Max нормализации все значения находятся в диапазоне [0, 1].

```

=====
Задание 3: Нормализация числовых признаков
=====
Стандартизация завершена, добавлены столбцы: Age_std, Fare_std, SibSp_std, Parch_std
Min-Max нормализация завершена, добавлены столбцы: Age_minmax, Fare_minmax, SibSp_minmax, Parch_minmax

Статистика исходных числовых признаков:

```

	Age	Fare	SibSp	Parch
count	891.0000	891.0000	891.0000	891.0000
mean	29.3616	32.2042	0.5230	0.3816
std	13.0197	49.6934	1.1027	0.8061
min	0.4200	0.0000	0.0000	0.0000
25%	22.0000	7.9104	0.0000	0.0000
50%	28.0000	14.4542	0.0000	0.0000
75%	35.0000	31.0000	1.0000	0.0000
max	80.0000	512.3292	8.0000	6.0000

```

Статистика после стандартизации:

```

	Age_std	Fare_std	SibSp_std	Parch_std
count	891.0000	891.0000	891.0000	891.0000
mean	0.0000	0.0000	0.0000	0.0000
std	1.0006	1.0006	1.0006	1.0006
min	-2.2242	-0.6484	-0.4745	-0.4737
25%	-0.5657	-0.4891	-0.4745	-0.4737
50%	-0.1046	-0.3574	-0.4745	-0.4737
75%	0.4333	-0.0242	0.4328	-0.4737
max	3.8916	9.6672	6.7842	6.9741

```

Статистика после Min-Max нормализации:

```

	Age_minmax	Fare_minmax	SibSp_minmax	Parch_minmax
count	891.0000	891.0000	891.0000	891.0000
mean	0.3637	0.0629	0.0654	0.0636
std	0.1636	0.0970	0.1378	0.1343
min	0.0000	0.0000	0.0000	0.0000
25%	0.2712	0.0154	0.0000	0.0000
50%	0.3466	0.0282	0.0000	0.0000
75%	0.4345	0.0605	0.1250	0.0000
max	1.0000	1.0000	1.0000	1.0000

Рисунок 4 – Результат нормализации числовых признаков

6 Итоговый набор данных

Выведены размер итогового набора данных и список всех созданных столбцов.

```

print(f"Размер итогового набора данных: {df_normalized.shape}")
print("\nВсе столбцы:")
print(list(df_normalized.columns))

```

Итоговый набор данных содержит 891 строку и 24 столбца. Добавлены закодированные и нормализованные признаки.

```

=====
Эксперимент завершён – обзор итогового набора данных
=====
Размер итогового набора данных: (891, 23)

Все названия столбцов:
['PassengerId', 'Survived', 'Pclass', 'Name', 'Sex', 'Age', 'SibSp', 'Parch', 'Ticket', 'Fare', 'Cabin', 'Embarked', 'Sex_LabelEncoded', 'Embarked_

Первые 3 строки итоговых данных:
  PassengerId  Survived  Pclass  \
0             1         0       3
1             2         1       1
2             3         1       3

                                Name    Sex  Age  SibSp  \
0                                Braund, Mr. Owen Harris  male  22.0      1
1  Cumings, Mrs. John Bradley (Florence Briggs Th...  female  38.0      1
2                                Heikkinen, Miss. Laina  female  26.0      0

  Parch    Ticket    Fare  ... Embarked_Q  Embarked_S  Age_std  \
0      0      A/5 21171  7.2500  ...      0.0         1.0 -0.565736
1      0      PC 17599  71.2833  ...      0.0         0.0  0.663861
2      0  STON/O2. 3101282  7.9250  ...      0.0         1.0 -0.258337

  Fare_std  SibSp_std  Parch_std  Age_minmax  Fare_minmax  SibSp_minmax  \
0 -0.502445  0.432793 -0.473674  0.271174   0.014151      0.125
1  0.786845  0.432793 -0.473674  0.472229   0.139136      0.125
2 -0.488854 -0.474545 -0.473674  0.321438   0.015469      0.000

  Parch_minmax
0          0.0
1          0.0
2          0.0

[3 rows x 23 columns]

```

Рисунок 5 – Итоговый набор данных

ЗАКЛЮЧЕНИЕ

В ходе работы выполнены три обязательных задания:

Устранение пропусков (медиана, мода)

Кодирование категориальных признаков (Label Encoding, One-Hot Encoding)

Нормализация числовых признаков (стандартизация, Min-Max)

В результате выполнения лабораторной работы были освоены ключевые методы предварительной обработки данных, необходимые для подготовки данных к построению моделей машинного обучения. Полученные навыки могут быть применены к любым другим наборам данных, содержащим пропуски, категориальные и числовые признаки. Правильная предварительная обработка данных является критически важным этапом, от которого напрямую зависит качество итоговых моделей.