



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Системы обработки информации и управления

ОТЧЕТ

ПО ЛАБОРАТОРНОЙ РАБОТЕ №5

ПО ДИСЦИПЛИНЕ «МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ»

НА ТЕМУ: Реализация алгоритма Policy Iteration

Студент ИУ5И-22М
(Группа)

Ду Линьсянь
(Подпись, дата) (И.О.Фамилия)

Преподаватель

Ю.Е.Гапанюк
(Подпись, дата) (И.О.Фамилия)

2026 г.

ЗАДАНИЕ

Ознакомление с базовыми методами обучения с подкреплением на примере алгоритма Policy Iteration.

Реализовать алгоритм Policy Iteration для среды CliffWalking-v1 из библиотеки Gymnasium. Алгоритм должен включать шаги оценивания стратегии (Policy Evaluation) и улучшения стратегии (Policy Improvement). Визуализировать процесс сходимости алгоритма и протестировать полученную оптимальную стратегию.

Параметры среды:

Размер: 4×12

Старт (S): левый нижний угол

Цель (G): правый нижний угол

Обрыв (X): клетки между стартом и целью на нижней строке

Награда за шаг: -1

Падение в обрыв: -100 (возврат на старт)

Достижение цели: 0 (конец эпизода)

1 Результаты выполнения

1.1. Процесс итераций алгоритма Policy Iteration




Рисунок 1 – Начальная случайная стратегия (итерация 1)

На начальной итерации стратегия выбирается случайным образом, функция ценности $V(s)$ близка к нулю. Стрелки указывают случайные направления движения агента.



Рисунок 2 – Промежуточная итерация

В процессе итераций стратегия постепенно улучшается. Стрелки начинают указывать более осмысленные направления — вправо и вверх, чтобы избежать обрыва и достичь цели.




Рисунок 3 – Промежуточная итерация

Алгоритм успешно сошёлся за конечное число итераций, что подтверждается выводом соответствующего сообщения.

1.2. График сходимости




Рисунок 4 – График сходимости алгоритма

Левый график показывает изменение функции ценности $V(s)$ для нескольких выбранных состояний по итерациям. Правый график отображает количество изменённых действий в стратегии на каждой итерации. Видно, что после определённой итерации стратегия перестаёт изменяться, что свидетельствует о достижении оптимальности.

1.3. Финальная оптимальная стратегия

Оптимальная стратегия предписывает агенту двигаться вправо вдоль нижней строки, аккуратно обходя обрыв, а затем вверх или прямо к цели. Функция ц

енности принимает максимальные значения вблизи цели и минимальные — на обрыве.




Рисунок 5 – Оптимальная стратегия $\pi(s)$ и функция ценности $V(s)$

1.4. Тестирование обученной стратегии



Рисунок 6 – Начало тестирования: стартовая позиция (S)

Агент находится в стартовой клетке (зелёная метка S). Начальная суммарная награда равна нулю.



Рисунок 7 – Процесс тестирования: движение агента

Агент движется в соответствии с оптимальной стратегией, получая награду -1 за каждый шаг. Синяя метка А показывает текущее положение агента.




Рисунок 8 – Успешное завершение эпизода: достижение цели (G)

Агент успешно достиг цели, эпизод завершён. Выводится сообщение о достижении цели и итоговая награда.

ЗАКЛЮЧЕНИЕ

В ходе выполнения лабораторной работы был реализован алгоритм Policy Iteration.

Основные результаты:

Алгоритм сошёлся за X итераций

Оптимальная стратегия позволяет агенту достигать цели, избегая обрыва
Функция ценности $V^*(s)$ принимает минимальное значение на обрыве и
максимальное вблизи цели

Вывод: Алгоритм Policy Iteration эффективно находит оптимальную
стратегию в дискретной среде с известной динамикой.

В данной работе был изучен и реализован алгоритм Policy Iteration – один
из базовых методов обучения с подкреплением, основанный на динамическом
программировании.

Комбинированный метод потенциально точен (нарушение $5e-8$), но
чувствителен к настройке параметров.

Штрафной и барьерный методы дают хорошие результаты (точность $1e-5$
— $1e-6$), но требуют большего числа итераций.

Метод проекции градиента с фиксированным шагом показал наихудший
результат из-за застревания в локальном минимуме.

Аналитическое решение подтверждает, что найденные численные
минимумы соответствуют теории.