



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Системы обработки информации и управления

ОТЧЕТ

ПО ЛАБОРАТОРНОЙ РАБОТЕ №6 ПО ДИСЦИПЛИНЕ «МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ»

НА ТЕМУ:

Предобработка и классификация текста

Студент ИУ5И-22М
(Группа)

Ду Линьсянь
(Подпись, дата) (И.О.Фамилия)

Преподаватель

Ю.Е.Гапанюк
(Подпись, дата) (И.О.Фамилия)

2026 г.

ЗАДАНИЕ

Освоить основные методы предобработки текста, включая токенизацию, частеречную разметку, лемматизацию, распознавание именованных сущностей и синтаксический анализ.

Изучить два различных подхода к классификации текстов: на основе TF-IDF векторизации и на основе векторных представлений слов Word2Vec.

Сравнить производительность различных методов классификации текстов.

Часть 1: Предобработка текста

Для предложения на русском языке "Мария купила красивую книгу в Москве вчера." выполнить следующие задачи:

Токенизация

Частеречная разметка

Лемматизация

Распознавание именованных сущностей

Синтаксический анализ

Часть 2: Классификация текста

Для набора данных для классификации новостных текстов выполнить классификацию двумя способами:

Способ 1: TF-IDF векторизация + Логистическая регрессия

Способ 2: Word2Vec векторные представления + Логистическая регрессия

Сравнить качество полученных моделей (точность и F1-меру).

1 Среда выполнения

Параметр	Описание
Среда разработки	Google Colab
Язык программирования	Python 3.12
Основные библиотеки	pymorphy3, natasha, razdel, scikit-learn, gensim, nltk

2 Результаты выполнения

2.1 Результаты части 1: Предобработка текста

(1) Токенизация

№	Токен
1	Мария
2	купила
3	красивую
4	книгу
5	в
6	Москве
7	вчера
8	.

(2) Частеречная разметка

Слово	Часть речи	Пояснение
Мария	PROPN	имя собственное
купила	VERB	глагол (прошедшее время)
красивую	ADJ	прилагательное

Слово	Часть речи	Пояснение
книгу	NOUN	существительное
в	ADP	предлог
Москве	PROPN	имя собственное (географическое название)
вчера	ADV	наречие
.	PUNCT	знак препинания

(3) Лемматизация

Исходное слово	Лемма
Мария	мария
купила	купить
красивую	красивый
книгу	книга
в	в
Москве	москва
вчера	вчера
.	.

(4) Распознавание именованных сущностей

Сущность	Тип	Пояснение
Мария	PER	имя человека
Москве	LOC	географическое название

(5) Синтаксический анализ

Слово	Часть речи	Тип синтаксической связи	Пояснение
Мария	PROPN	nsubj	именное подлежащее

Слово	Часть речи	Тип синтаксической связи	Пояснение
купила	VERB	root	корень предложения (сказуемое)
красивую	ADJ	amod	адъективное определение
книгу	NOUN	obj	прямое дополнение
в	ADP	case	падежный маркер
Москве	PROPN	obl	обстоятельство места
вчера	ADV	advmod	обстоятельственное наречие
.	PUNCT	punct	пунктуация

4.2 Результаты части 2: Классификация текста

Информация о наборе данных:

Обучающая выборка: 1584 образца

Тестовая выборка: 397 образцов

Категории: новости о бейсболе (rec.sport.baseball) и космосе (sci.space)

Способ 1: TF-IDF + Логистическая регрессия

Показатель	Значение
Точность (Accuracy)	0.9924
F1-мера (F1-score)	0.9928

Способ 2: Word2Vec + Логистическая регрессия

Показатель	Значение
Точность (Accuracy)	0.8690
F1-мера (F1-score)	0.8744

3 Анализ результатов

5.1 Анализ предобработки текста

Токенизация: Инструмент корректно разделил предложение на слова и знаки препинания, получив 8 токенов.

Частеречная разметка: Каждое слово получило правильную частеречную метку. Система успешно различает имена собственные (PROPN), глаголы (VERB), прилагательные (ADJ), существительные (NOUN), предлоги (ADP), наречия (ADV) и знаки препинания (PUNCT).

Лемматизация: Все слова успешно приведены к нормальной форме. Глагол купила приведён к купить, прилагательное красивую к красивый и т.д.

Распознавание именованных сущностей: Система правильно определила имя человека "Мария" (тип PER) и географическое название "Москве" (тип LOC).

Синтаксический анализ: Построено корректное дерево зависимостей предложения:

Корень предложения: купила (сказуемое)

Подлежащее: Мария

Прямое дополнение: книгу

Обстоятельство места: Москве

Обстоятельство времени: вчера

Синтаксическая структура ясно выражает смысл: "Мария купила книгу в Москве вчера".

5.2 Сравнительный анализ методов классификации

Совмещённый график траекторий всех пяти методов

Метод	Точность	F1-мера
TF-IDF + Логистическая регрессия	99.24%	99.28%
Word2Vec + Логистическая регрессия	86.90%	87.44%

Анализ различий в производительности:

Метод TF-IDF показывает лучшие результаты: Точность достигает 99.24%, что на 12.34% выше, чем у метода Word2Vec.

Причины:

TF-IDF эффективно выделяет ключевые слова текста, что особенно полезно для различения тем новостей (бейсбол vs космос)

Word2Vec с усреднением векторов слов теряет информацию о порядке слов и весах ключевых слов

Для коротких текстов или задач с четкими тематическими признаками частотные методы часто превосходят нейросетевые

Преимущества Word2Vec не проявились в полной мере: При достаточном объеме данных Word2Vec способен улавливать смысловые отношения, однако в данном эксперименте из-за ограниченного объема данных его преимущества не проявились.

ЗАКЛЮЧЕНИЕ

В части предобработки текста: С использованием библиотек `ru morphology3`, `natasha` и `razdel` успешно выполнены все задачи предобработки русского текста. Результаты показывают, что эти инструменты способны точно обрабатывать морфологию и синтаксис русского языка.

В части классификации текста:

Метод на основе TF-IDF достиг точности 99.24%, что является отличным результатом.

Метод на основе Word2Vec показал точность 86.90%. Хотя этот результат ниже, чем у TF-IDF, метод всё ещё демонстрирует хорошую способность к классификации.

При выборе метода классификации текста следует учитывать особенности конкретной задачи: для задач с явно выраженными ключевыми словами лучше подходит TF-IDF; для задач, требующих понимания семантики, методы векторных представлений (Word2Vec и подобные) имеют больший потенциал.

Рекомендации: Для улучшения результатов классификации с использованием Word2Vec можно предложить следующие направления:

Использование предобученных векторных представлений

Применение более сложных методов получения векторных представлений документов (например, Doc2Vec)

Увеличение объёма обучающей выборки